

# 数据挖掘导论lab1报告

3220106424 张天逸

## 数据集来源

我选择的数据集是Polycystic Ovary Syndrome PCOS (<https://www.kaggle.com/datasets/lucass0s0/polycystic-ovary-syndrome-pcos/data>)

这是一个 3 000 例的合成 PCOS 临床指标数据集，提供年龄、BMI、雄激素水平、月经状况和卵泡计数等 5 个核心特征，用于探索或建模 PCOS 诊断。

维度	说明
数据类型	合成临床数据，基于 2003 年国际共识的 <b>Rotterdam 诊断标准</b> 随机生成
样本量	3 000 条记录，代表 18-44 岁育龄女性
目标列	<b>PCOS_Diagnosis</b> 0 = 未诊断 PCOS 1 = 符合 Rotterdam 至少 2 项标准

字段总览	• <b>Age</b> (整数, 18-44)
	• <b>BMI</b> (体质指数, 8.5-44.7)
	• <b>Menstrual_Irregularity</b> (二元, 月经是否不规律)
	• <b>Testosterone_Level(ng/dL)</b> (总睾酮, 20.5-136.4)
	• <b>Antral_Follicle_Count</b> (窦卵泡计数, 3-39)
	• <b>PCOS_Diagnosis</b> (二元, 诊断结果)

## 部署

依赖: pandas numpy scikit-learn matplotlib scipy

如果存在python版本冲突，建议创建虚拟环境：

```
cd lab1 python -m venv .venv # 或 conda create -n pcos python=3.10 source .venv/bin/activate # Windows:
.venv\Scripts\activate
```

## 预处理

预处理部分的代码可分为以下这些部分：

- 去重 `df = pd.read_csv(input_csv).drop_duplicates()` 读入 CSV 后立即删除完全重复的样本，避免同一人数  
据多次出现造成统计偏差。
- 缺失值填补 `df = df.fillna(df.median(numeric_only=True))` 对所有数值列用列中位数填补 NaN，保持分布  
不受极端值拉动。
- 异常值截断 (Winsorize) python  
for col in numeric\_cols:  
    q1,q3 = df[col].quantile([.25,.75])  
    iqr = q3-q1

`df[col] = df[col].clip(q1-1.5iqr, q3+1.5iqr)` 对 4 个连续特征 (Age、BMI、睾酮、AFC) 按  $1.5 \times \text{IQR}$  规则截断上下尾, 使极端值不再过度影响均值与模型梯度, 同时长尾特征性仍保留。

#### 4. 分位数离散化 python

`discretizer = KBinsDiscretizer(n_bins=n_bins, encode="ordinal", strategy="quantile")`  
`df[["BMI_bin", "Testosterone_bin"]] = discretizer.fit_transform(df[["BMI", "Testosterone_Level(ng/dL)"]])` 将 BMI 和 Testosterone 分成 `n_bins` (默认 4) 个等频箱, 生成离散特征 `*_bin`。便于后续做卡方检验、信息增益或可视化。

#### 5. 标准化 python

`scaler = StandardScaler()`  
`df[numeric_cols] = scaler.fit_transform(df[numeric_cols])` 让 Age、BMI、睾酮、AFC 均转化为 均值 0 / 方差 1, 消除量纲差异, 使距离度量与梯度下降更稳定。

#### 6. 可选 PCA 降维 python

`if with_pca:`  
`pca = PCA(n_components=2, random_state=42)`  
`df[["PC1", "PC2"]] = pca.fit_transform(df[numeric_cols])` 如 `with_pca=True`, 使用主成分分析将 4 个数值特征投影到 2 维, 便于可视化或降维建模; PC1、PC2 解释累计方差 > 95 %。

#### 7. 保存结果 `df.to_csv(output_csv, index=False)` 输出为 `new_pcos_processed.csv`, 供后续模型或可视化脚本直接读取。

## 可视化

可视化部分的代码可以分为以下这些部分:

1. 循环遍历每一数值列 `for col in numeric:` 逐列绘图, 保持自动化
2. 新建画布 `plt.figure()` 避免多图叠加 (每轮清空)
3. Boxplot `plt.boxplot(df[col].dropna())` `plt.title(f"Boxplot of {col}")` `plt.savefig(... "_box.png")` 展示中位数、四分位距 (IQR) 与极端值; 保存为 `figs/<列名>_box.png`
4. Histogram `plt.hist(df[col].dropna(), bins=30)` `plt.title("Histogram ...")` `plt.savefig(... "_hist.png")` 30 个柱子查看分布形态 (偏态、峰度、多峰); 保存 `_hist.png`
5. QQ Plot `stats.probplot(df[col].dropna(), dist="norm", plot=plt)` `plt.title("QQ Plot ...")` `plt.savefig(... "_qq.png")` 把样本分位与正态分位比对, 检验正态性; 保存 `_qq.png`
6. 关闭画布 `plt.close()` 释放内存, 确保下一轮不会把前面内容叠进来

## 分析结果

可视化图形揭示的主要特征

### 1.1 年龄 (Age)

- **直方图**近似钟形但轻度左偏——年轻样本略多。
- **QQ 图**几乎贴线 → 年龄分布与正态差异不大。  
→ 数据集聚焦于 18–35 岁核心生育年龄段, 年龄本身对 PCOS 诊断区分度有限。

### 1.2 BMI

- **盒须图**: 上须显著长——高 BMI 离群值 (> 30) 集中在 PCOS 人群。
- **直方图**: 右偏+长尾, 即便 Winsorize 后仍明显。

- **QQ 图**：上端点远离直线说明右尾重。  
→ 肥胖是 PCOS 共病的重要信号，清洗后仍保留了诊断信息。
- ### 1.3 睾酮 (Testosterone\_Level)
- **所有三图**都显示浓重右左偏 → 高雄激素血症是 Rotterdam 三大诊断标准之一；数据合成过程很好地模拟了该临床特征。
- ### 1.4 窦卵泡计数 (AFC)
- **峰度高**（直方图尖且窄）、**QQ 图**上端明显上翘  
→ 反映 PCOS 卵巢“多囊”影像学特征；与睾酮、月经失调共同组成高相关组合（corr ≈ 0.86 ~ 0.78）。
- ### 1.5 PCA 主成分 (PC1, PC2)
- 处理后 PC1、PC2 近似正态 → 说明标准化+PCA 消除了长尾，便于聚类或判别可视化。
  - **\*\*散点图（若另外绘制）\*\***展示健康 vs PCOS 在 PC1-PC2 平面已有粗分隔，可用于降维演示。

“有 vs 无” 预处理对可视化的影响

视角	原始数据	预处理后	差异
异常值	睾酮 > 250 ng/dL、BMI > 45、AFC > 50 等极端点淹没画面	Winsorize 截断至 1.5×IQR，盒须图更可读	极端样本权重下降，图形不再“散弹枪”
尺度	不同列量纲差异大 → PCA 前两维几乎只由 AFC 支配	StandardScaler 归一化后 PCA 方差更均衡	PC1/PC2 解释>95 % 总方差且近正态
直方图形态	极长右尾吞掉大部分区分度	尾巴被截但偏态仍在	易看出 BMI / Testosterone 幂律分布
QQ 图	上端远离红线到“折腰”状态	线性显著改善（PC1, PC2 近于直线）	统计检验更可信；仍可感知右偏
离散化列	无	生成 BMI_bin & Testosterone_bin（4 等频）	便于做分组箱线图 / 卡方检验

预处理 **减少了可视化的“噪音”**（极值、尺度不一），让箱线图和 QQ 图的形态更加易读，同时又 **保留了医学上有价值的右偏长尾**，在实践中能提高模型稳定性和解释性。